

ДИПЛОМНЫЙ ПРОЕКТ

ДПО «КОМПЬЮТЕРНАЯ ЛИНГВИСТИКА»

ДИСЦИПЛИНА «МАШИННОЕ ОБУЧЕНИЕ»

«Выявление ИИ-контента с помощью моделей машинного обучения - 2026»

Автор: Грачева Светлана Владимировна

НИУ «Высшая Школа Экономики» (г. Москва)

О ПРОЕКТЕ

- По мере того, как большие языковые модели становятся все более совершенными, различение контента, написанного ИИ, от текста, написанного человеком, становится все более сложной задачей в исследованиях в области обработки естественного языка, журналистике, академической среде и модерации контента.
- Этот проект и набор данных был создан для того, чтобы помочь сообществу обучать, оценивать и сравнивать модели распознавания текста, созданные искусственным интеллектом.
- Гипотеза - Можно ли найти лучший способ среди инструментов машинного обучения для оценки и проверки оригинальности текста.

ДЛЯ КОГО

- Исследователи в области обработки естественного языка (NLP), которые проводят сравнительный анализ алгоритмов обнаружения;
- Специалисты по машинному обучению, которые создают классификаторы текста и ИИ-детекторы;
- Студенты, изучающие бинарную классификацию текста;
- Все, кто исследует границу между языком, созданным человеком, и языком, созданным машиной;

КОРПУС ДАННЫХ

Источник: [kaggle.com](https://www.kaggle.com)

Причина - доступность

- Реально размеченных данных на русском языке в доступе нет. Необходимо собирать и далее размечать под конкретные задачи;
- Отсутствие стилометрических характеристик конкретных авторов для отслеживания;
- Есть риск нарушения прав при использовании русскоязычного корпуса;

Минусы:

Иностранный язык

Многие детекторы изначально обучались на англоязычных корпусах, поэтому на русском их точность заметно ниже.

КОРПУС ДАННЫХ

- Корпус данных содержит 2000 размеченных текстовых образцов, охватывающих три реальные сферы: академические тексты, новостные статьи и публикации в социальных сетях.
- Каждый образец помечен как написанный человеком или созданный искусственным интеллектом; при этом образцы, сгенерированные ИИ, были получены с помощью двух наиболее широко используемых в 2025–2026 годах моделей — GPT-4o и Gemini 2.0.
- Человеческие тексты были написаны с использованием методов шаблонов и вариаций, созданных человеком, для имитации аутентичных стилей письма в различных областях;
- Тексты, созданные с помощью ИИ, генерировались на основе подсказок по стилю, разработанных для имитации специфических для данной области правил письма;
- Особенности:
- Дисбаланс классов: 1334 примера от людей против 666 примеров от ИИ (соотношение ~2:1).
- Длина текста невелика (19–52 слова, в среднем ~37), что делает его подходящим для задач выделения предложений. Они показывают, какие отрывки повлияли больше всего на классификацию.
- Корпус англоязычной среды.




	text_id	label	source_model	domain	text_content	topic_hint	word_count	avg_sentence_length	generation_method
0	TXT_0001	human	human	social	can we talk about gene editing ethics for a se...	gene editing ethics	27	13.5	template+human_variation
1	TXT_0002	human	human	social	update on election integrity concerns: it's co...	election integrity concerns	20	10.0	template+human_variation
2	TXT_0003	ai	gemini-2.0	news	Analysts are closely watching developments rel...	climate change adaptation strategies	39	13.0	style_simulation
3	TXT_0004	human	human	academic	This paper examines genomic research breakthro...	genomic research breakthroughs	49	16.3	template+human_variation
4	TXT_0005	ai	gpt-4o	academic	Existing literature on student debt crisis has...	student debt crisis	42	10.8	style_simulation

АНАЛИЗ

- ЭТАПЫ ИССЛЕДОВАНИЯ
- Установка зависимостей, библиотек и загрузка корпуса данных;
- Обзор датасета;
- Разведочный анализ (EDA);
- Тематический анализ;
- Языковые закономерности;
- ML Model (TF-IDF+Logistic regression);


АНАЛИЗ

Dataset Composition Overview




АНАЛИЗ



Label Count per Domain




Label % per Domain




Linguistic Length Features: Human vs AI






Most Frequent Words: Human vs AI

Top 20 Words — Human




Top 20 Words — AI



АНАЛИЗ

- Human vocab richness:



АНАЛИЗ

=== Classification Report ===


	precision	recall	f1-score	support
Human	1.00	1.00	1.00	267
AI	1.00	1.00	1.00	133
accuracy			1.00	400
macro avg	1.00	1.00	1.00	400
weighted avg	1.00	1.00	1.00	400

ROC-AUC Score: 1.0000

5-Fold CV F1 Scores : [1. 1. 1. 1. 1.]

Mean F1 : 1.0000 ± 0.0000

TF-IDF Feature Importance (Logistic Regression Coefficients)




КЛЮЧЕВЫЕ ВЫВОДЫ

- Все три области (академическая, новостная, социальная) представлены почти в равной степени (~33% каждая), что делает его хорошо сбалансированным эталонным набором данных.
- Тексты, созданные с помощью ИИ, как правило, имеют немного большую среднюю длину предложений и более формальный словарный запас по сравнению с текстами, созданными людьми.
- Тексты, созданные людьми, демонстрируют более богатый словарный запас (соотношение типов и токенов), отражая более естественное разнообразие в выборе слов.
- ПРОИЗВОДИТЕЛЬНОСТЬ МОДЕЛЕЙ
- Базовая модель TF-IDF + логистическая регрессия демонстрирует высокую производительность, учитывая размер набора данных.
- Лучшие признаки, предсказывающие результаты ИИ, склоняются к формальным, структурированным академическим фразам.
- Лучшие признаки, предсказывающие результаты человека, отражают неформальные, разговорные языковые модели.

ГЛАВНОЕ

- Методы машинного обучения могут быть эффективно применены для оценки и проверки определения оригинальности текста.
 - Точность вероятности достаточно высока. Но пока - не сама точность. Сфера ИИ - динамично развивается.
 - Модели машинного обучения следует использовать как индикатор, а не окончательный результат. Рассматривать в совокупности с другими закономерностями история правок автором.
 - Точность зависит от языка, сложности текста и уровня самой модели.
 - Сочетать распознавания ИИ-текста с ручной проверкой.
-
- Дисклеймер. Данное исследование предназначено для использования в учебных целях. Не несет ответственности за результаты. Результаты не являются абсолютными.



СПАСИБО ЗА ВНИМАНИЕ!